

Caderno Técnico do CLARITI

- [CADERNO TÉCNICO DO CLARITI](#)
 - [COMO USAR ESTE CADERNO](#)
- [PARTE 1 — O VOCABULÁRIO, EXPLICADO DO ZERO](#)
 - [1.1 O mundo do dado público de saúde](#)
 - [1.2 Os conceitos clínicos que usamos](#)
 - [1.3 Os conceitos de banco de dados](#)
 - [1.4 Os conceitos de machine learning](#)
 - [1.5 Como se mede se um modelo é bom](#)
 - [1.6 Vazamento de dados \(data leakage\)](#)
 - [1.7 Privacidade e os conceitos de proteção](#)
 - [1.8 Os conceitos de IA generativa que usamos](#)
- [PARTE 2 — A ARQUITETURA, CAMADA POR CAMADA](#)
 - [2.1 O desenho em uma frase](#)
 - [2.2 As sete camadas](#)
 - [2.3 Por que essa ordem importa](#)
 - [2.4 As cinco views publicáveis](#)
 - [2.5 As sete ferramentas da Athena](#)
- [PARTE 3 — OS DADOS: DE ONDE VIERAM E O QUE VIRARAM](#)
 - [3.1 O recorte](#)
 - [3.2 Os números que sustentam o pitch](#)
 - [3.3 A chave de paciente, e por que ela é aproximada](#)
 - [3.4 O achado que abre o pitch, dito com precisão](#)
 - [3.5 Sazonalidade](#)
- [PARTE 4 — O MODELO: CADA DECISÃO E O PORQUÊ](#)
 - [4.1 A pergunta que o modelo responde](#)
 - [4.2 A definição exata do alvo](#)
 - [4.3 As features e o que cada uma significa](#)
 - [4.4 As métricas finais, com a régua de comparação](#)
 - [4.5 Por que treino em 2022–2023 e teste em 2024](#)
 - [4.6 A comparação baseline versus full](#)
 - [4.7 O que é bootstrap, já que ele aparece na defesa](#)
- [PARTE 5 — A GOVERNANÇA: k=5, FALLBACK E POR QUÊ](#)
 - [5.1 O problema real que motivou tudo](#)
 - [5.2 Por que a resposta não foi “hashear mais campos”](#)
 - [5.3 O que é k=5, na prática do CLARITI](#)
 - [5.4 Por que 5](#)
 - [5.5 O fallback hierárquico, que é o diferencial](#)
 - [5.6 Por que a view de polo está fora do NL2SQL](#)
 - [5.7 Os dois regimes de LGPD](#)
- [PARTE 6 — A CAMADA DE IA: SELECT AI, AGENT E AS SETE FERRAMENTAS](#)
 - [6.1 Os três papéis, que não se confundem](#)

- [6.2 Como o Select AI funciona, passo a passo](#)
- [6.3 As cinco consultas NL2SQL homologadas](#)
- [6.4 O processo de homologação, que é o diferencial invisível](#)
- [6.5 O Agent, e as quatro reprovações de QA](#)
- [6.6 O dicionário CID-10, e por que ele virou requisito](#)
- [6.7 Estabilidade da narrativa, e a decisão de parar de apertar](#)
- [PARTE 7 — OS ERROS QUE ENCONTRAMOS E CORRIGIMOS](#)
 - [7.1 A tautologia da feature de histórico](#)
 - [7.2 O overclaim do PSM](#)
 - [7.3 A hipótese da idade que não se sustentou](#)
 - [7.4 O grupo que quase ficou de fora](#)
 - [7.5 O erro de fonte que voltou três vezes](#)
- [PARTE 8 — OS LIMITES: O QUE O CLARITI NÃO FAZ](#)
- [PARTE 9 — PERGUNTAS PROVÁVEIS DA BANCA](#)
 - [Bloco A — O achado de abertura](#)
 - [Bloco B — O modelo](#)
 - [Bloco C — Governança e privacidade](#)
 - [Bloco D — A IA generativa](#)
 - [Bloco E — Produto e viabilidade](#)
 - [Bloco F — As perguntas difíceis](#)
- [PARTE 10 — PENDÊNCIAS CONHECIDAS \(USO INTERNO\)](#)
 - [10.1 O critério “Uso Correto dos Formatos” — risco alto](#)
 - [10.2 Integração ponta a ponta](#)
 - [10.3 Divergências numéricas entre gerações](#)
 - [10.4 O que ainda não foi isolado](#)
 - [FECHAMENTO](#)

CADERNO TÉCNICO DO CLARITI

Tudo o que foi construído, por que foi construído assim, e como defender cada decisão

Equipe Seraph · Challenge FIAP + Oracle 2026 · Banca 15/09/2026 Versão 1.0 · escrito a partir da memória canônica do projeto (`memoria_projeto/`), dos registros do Codex e das evidências em `evidencias_m5/` .

COMO USAR ESTE CADERNO

Ele tem dez partes e é feito para ser lido do começo ao fim uma vez, e depois consultado por seção.

- **Partes 1 e 2** explicam os conceitos do zero. Se você já domina, pule.
- **Partes 3 a 7** são o projeto em si: dados, modelo, governança, IA, erros corrigidos.

- **Parte 8** é a lista do que o CLARITI **não** faz. Decore essa parte. É ela que evita que vocês prometam demais sob pressão.
- **Parte 9** são as perguntas prováveis, com resposta pronta e réplica.
- **Parte 10** são as pendências conhecidas, para uso interno.

Regra de ouro para a banca: nenhuma frase deste caderno afirma mais do que a evidência sustenta. Se na hora da pergunta você não lembrar do número, diga o que o teste demonstra e ofereça buscar o número exato. Isso vale mais que um número errado dito com confiança.

PARTE 1 — O VOCABULÁRIO, EXPLICADO DO ZERO

Esta parte assume que você não sabe nada. Cada termo é explicado com uma analogia e depois com a definição técnica.

1.1 O mundo do dado público de saúde

SUS (Sistema Único de Saúde). O sistema público de saúde brasileiro. Tudo que acontece nele gera registro administrativo, e esses registros são publicados de forma anonimizada. É daí que vêm todos os nossos dados. Não usamos nenhum dado privado, nenhum convênio, nenhum prontuário.

DATASUS. O braço de tecnologia do Ministério da Saúde. É quem publica as bases. Pense nele como o “cartório” que guarda e divulga os registros.

SIH/SUS (Sistema de Informações Hospitalares). A base das **internações**. Cada linha é uma internação que aconteceu num hospital do SUS. É a nossa fonte principal: dela vêm as 813.422 internações que processamos.

AIH (Autorização de Internação Hospitalar). O documento administrativo que autoriza e depois fatura uma internação. Na prática, uma linha do SIH corresponde a uma AIH. Quando falamos “valor médio de AIH”, é o valor faturado daquela internação.

CNES (Cadastro Nacional de Estabelecimentos de Saúde). O cadastro dos hospitais, postos e clínicas. É de onde vem o número de **leitos cadastrados** de cada município. Atenção, e isso é importante: o CNES diz quantos leitos **existem no cadastro**, não quantos estão livres agora. Voltaremos a isso.

SIOPS (Sistema de Informações sobre Orçamentos Públicos em Saúde). Onde os municípios declaram quanto gastaram em saúde. Usamos a subfunção “Atenção Básica” para medir investimento em atenção primária.

SIA (Sistema de Informações Ambulatoriais). A base dos **atendimentos ambulatoriais**, ou seja, o que acontece fora da internação: consulta, exame, procedimento. Usamos para medir cobertura real de UBS.

IBGE. Fonte da população de cada município, necessária para calcular taxas por 100 mil habitantes.

1.2 Os conceitos clínicos que usamos

CSAP / ICSAP (Condições Sensíveis à Atenção Primária / Internações por CSAP). Este é o conceito central do projeto, então vale a analogia.

Imagine um vazamento numa torneira de casa. Se você aperta a borracha no primeiro ping, resolve por dois reais. Se você ignora, em seis meses você tem infiltração na parede e gasta dois mil. A internação por CSAP é a “infiltração”: é a internação que, **em tese**, poderia ter sido evitada se a atenção primária (o posto de saúde, o agente comunitário, o acompanhamento do diabético) tivesse funcionado bem antes.

Tecnicamente: existe uma **lista oficial** de diagnósticos considerados sensíveis à atenção primária, publicada pelo Ministério da Saúde (Portaria SAS/MS 221/2008). Ela agrupa os diagnósticos em 19 grupos, como asma, insuficiência cardíaca, diabetes, infecção urinária, pneumonias bacterianas. Quando uma internação tem um diagnóstico principal dessa lista, ela é classificada como ICSAP.

Cuidado com a palavra “evitável”. Uma internação por CSAP não é necessariamente evitável naquele caso específico. É um **indicador populacional**: um município com muitas ICSAP provavelmente tem problema de acesso à atenção primária. Dizer “essa internação era evitável” sobre um paciente é errado e a banca pode cobrar isso. A forma correta é “internação sensível à atenção primária”.

UTI no registro. No SIH existe um campo que indica quantas diárias de UTI a internação consumiu (`uti_mes_to`). Quando esse campo é maior que zero, a internação passou por UTI. Nosso recorte é justamente esse: internações que consumiram UTI. Motivo: o Challenge é sobre **manejo de leitos**, e leito de UTI é o recurso mais escasso e mais caro da rede.

Reinternação em 30 dias. Quando uma pessoa volta a ser internada pouco tempo depois de ter recebido alta. É um indicador clássico de qualidade e de continuidade do cuidado no mundo inteiro. Voltaremos à definição exata que usamos, porque ela tem uma sutileza que a banca pode explorar.

CID-10. A Classificação Internacional de Doenças, décima revisão. É um código padronizado para cada diagnóstico. `A41.9` é septicemia não especificada, `I21.9` é infarto agudo do miocárdio não especificado. Sem esse dicionário, o dado bruto traz só o código, ilegível para um gestor.

1.3 Os conceitos de banco de dados

Banco de dados relacional. Pense numa coleção de planilhas que sabem conversar entre si. Cada planilha é uma **tabela**, cada linha é um registro, cada coluna é um campo. Elas se ligam por chaves (o código do município numa tabela aponta para o código do município na outra). SQL é a linguagem usada para perguntar coisas a esse conjunto.

View (visão). Uma consulta salva com nome. Não guarda dado novo: guarda a **pergunta**. Quando alguém consulta a view, o banco executa a consulta original naquele momento. Analogia: é uma janela recortada para um pedaço do dado, e você só enxerga o que a janela deixa ver. É o principal

instrumento de governança do CLARITI, porque a janela pode esconder o que não pode ser mostrado.

Função PL/SQL. PL/SQL é a linguagem de programação do Oracle, que roda **dentro** do banco. Uma função recebe parâmetros, executa uma lógica e devolve um resultado. No CLARITI, as funções são a barreira determinística: elas checam a regra de privacidade antes de devolver qualquer coisa. “Determinístico” quer dizer que, para a mesma entrada, a saída é sempre a mesma, sem qualquer participação de IA.

Autonomous Database. O banco de dados gerenciado da Oracle na nuvem. “Autonomous” porque ele faz sozinho tarefas que um administrador faria (backup, ajuste, patch). A versão 26ai é a que traz os recursos de IA que usamos.

JSON. Um formato de texto para dados estruturados, muito usado em APIs. Parece isto:

```
{"municipio": "Colina", "ano": 2024, "internacoes": 104}
```

É o formato em que nossas funções devolvem resultado para a Athena.

CSV. Um arquivo de texto com valores separados por vírgula, uma linha por registro. É o formato mais simples de troca de dados. O dicionário CID-10 veio em CSV.

External Table (tabela externa). Um recurso do Oracle que permite ler um arquivo (CSV, por exemplo) **como se fosse uma tabela**, sem importar o conteúdo para dentro do banco. O arquivo continua lá fora, o banco só sabe interpretá-lo. Isso é relevante porque é um dos critérios oficiais de avaliação do Challenge.

1.4 Os conceitos de machine learning

Esta seção é a mais importante para a arguição técnica. Vá devagar.

Machine learning, em uma frase. É um método para encontrar padrões em dados do passado e usar esses padrões para pontuar casos novos. Não é mágica e não é inteligência: é estatística aplicada com muito poder computacional.

Classificação binária. O tipo de problema que temos. Para cada internação, queremos responder uma pergunta de sim ou não: “esta internação foi seguida por um retorno à UTI em até 30 dias?”. O modelo não responde sim ou não diretamente: ele devolve um **número entre 0 e 1**, que é o score de risco. Quanto mais perto de 1, mais o padrão daquela internação se parece com os casos que tiveram retorno.

Variável-alvo (target). A coluna que queremos prever. No nosso caso, `reinternacao_30d`, que vale verdadeiro ou falso.

Features (variáveis preditoras). As colunas que o modelo usa para calcular o score. No nosso caso: número de internações prévias em 365 dias, diárias de UTI, dias de permanência, diagnóstico principal, distância ao polo, idade, sexo, grupo CSAP.

Treino e teste. Você não pode avaliar um modelo nos mesmos dados em que ele aprendeu, pelo mesmo motivo que não se avalia um aluno na prova cujas respostas ele decorou. Separa-se o dado:

uma parte para o modelo aprender (**treino**), outra que ele nunca viu para medir o desempenho (**teste**).

Teste fora do tempo (out-of-time). Uma separação mais rigorosa que a comum. Em vez de sortear linhas aleatoriamente, separa-se por **período**: treinamos com 2022 e 2023, testamos em 2024. Por que isso é melhor? Porque simula o uso real: um modelo colocado em produção vai pontuar casos do futuro, não casos sorteados do mesmo período. Se o comportamento da rede mudar de um ano para o outro, o teste fora do tempo captura essa degradação; o sorteio aleatório esconde. **Este é um ponto forte do projeto e vale ser dito na banca.**

XGBoost. O algoritmo que usamos. Vamos por partes.

Uma **árvore de decisão** é uma sequência de perguntas de sim ou não. “Teve internação nos últimos 365 dias? Se sim, ficou mais de 10 dias internado? Se sim, escore alto.” Uma árvore sozinha é fraca e decora o treino.

Boosting é a ideia de treinar muitas árvores **em sequência**, onde cada árvore nova é treinada especificamente para corrigir os erros que as anteriores cometeram. A primeira árvore erra em certos casos; a segunda é treinada dando mais peso a esses casos; e assim por diante. No fim, soma-se a contribuição de todas.

XGBoost (eXtreme Gradient Boosting) é a implementação mais usada dessa ideia. Ela é popular porque é rápida, lida bem com dados tabulares (tabela com colunas heterogêneas, que é exatamente o nosso caso) e tem regularização embutida.

Por que XGBoost e não regressão logística ou rede neural? Resposta curta e defensável: para dado tabular com variáveis heterogêneas e relações não lineares, boosting de árvores é o padrão da indústria e costuma bater regressão logística sem exigir que você especifique interações à mão. Rede neural precisa de muito mais dado e não traz ganho conhecido em tabular deste porte. Além disso, XGBoost é **nativo no OML4Py**, o que nos permitiu treinar dentro do Oracle sem exportar a base.

Os hiperparâmetros (aqui entra o “lambda” que você perguntou). Hiperparâmetro é uma configuração que **você escolhe antes** do treino, diferente dos parâmetros que o modelo aprende sozinho. Os principais do XGBoost:

Hiperparâmetro	O que faz	Analogia
<code>max_depth</code>	profundidade máxima de cada árvore	quantas perguntas encadeadas cada árvore pode fazer. Mais fundo = mais capacidade de decorar
<code>eta</code> (learning rate)	quanto cada árvore nova pode corrigir	tamanho do passo. Passo pequeno = aprendizado lento e mais estável
<code>num_round</code> (n_estimators)	quantas árvores no total	quantas rodadas de correção
<code>subsample</code>	fração das linhas usada por árvore	cada árvore vê só uma amostra, o que reduz decoreba
<code>colsample_bytree</code>	fração das colunas por árvore	idem, mas para variáveis
<code>lambda</code> (reg_lambda)	regularização L2	uma “multa” proporcional ao quadrado do peso de cada folha.

Hiperparâmetro	O que faz	Analogia
		Penaliza pesos grandes e força o modelo a ser mais conservador
<code>alpha</code> (<code>reg_alpha</code>)	regularização L1	multa proporcional ao valor absoluto do peso. Tende a zerar pesos, o que faz seleção de variáveis
<code>gamma</code>	ganho mínimo para abrir um nó	só divide a árvore se a divisão melhorar o suficiente
<code>scale_pos_weight</code>	peso da classe minoritária	compensa desbalanceamento entre positivos e negativos

O que é regularização, em palavras simples. Um modelo sem freio tende a **decorar** o treino, inclusive o ruído. Quando isso acontece, ele vai muito bem no treino e mal no teste. Isso se chama **overfitting** (sobreajuste). Regularização é o freio: uma penalidade matemática que torna caro para o modelo criar regras muito específicas. `lambda` é a penalidade que pune pesos grandes ao quadrado (L2); `alpha` pune o valor absoluto (L1) e costuma zerar pesos inteiros.

A configuração documentada do nosso treino (`outputs/HANDOFF_OML4PY_PARA_CLAUDE_2026-09-11.md`, Gate 6): booster de árvores (`gbtree`), `max_depth = 6`, `eta = 0,1`, `num_round = 100`, semente 42 quando suportada, com balanceamento de classes pelo mecanismo nativo do Oracle.

Ressalva honesta, e ela é importante: essa é a configuração **planejada e registrada no handoff**. Os valores efetivamente gravados no modelo final estão em `USER_MINING_MODEL_SETTINGS` no Oracle. Se a banca perguntar o hiperparâmetro exato, a resposta correta é citar essa configuração e dizer que ela está persistida e auditável no dicionário do banco. Não afirme um valor de `lambda` específico: nós usamos o **default do XGBoost nativo do Oracle**, que não foi alterado explicitamente.

1.5 Como se mede se um modelo é bom

Esta é a seção que mais derruba equipe de graduação em arguição. Leia duas vezes.

Prevalência. A proporção de casos positivos no conjunto. No nosso teste de 2024, a prevalência é **14,8483%**, ou seja, cerca de 15 em cada 100 interações tiveram o retorno estudado. Esse número é a régua: qualquer coisa que o modelo faça precisa ser comparada a ele.

Por que acurácia não serve. Se 85% dos casos são negativos, um modelo que responde “não” para todo mundo acerta 85%. Acurácia alta, utilidade zero. Por isso nunca apresentamos acurácia.

Matriz de confusão. A tabela dos quatro resultados possíveis: verdadeiro positivo (o modelo disse sim e era sim), falso positivo (disse sim e era não), verdadeiro negativo, falso negativo. Todas as métricas abaixo derivam dela.

Sensibilidade (recall). Dos casos que realmente tiveram o desfecho, quantos o modelo pegou. É a métrica que importa quando deixar passar é caro.

Precisão. Dos casos que o modelo apontou, quantos realmente tiveram o desfecho. É a métrica que importa quando agir à toa é caro. No nosso caso, as duas importam, porque a equipe da Marina tem capacidade limitada.

ROC-AUC. A métrica mais citada e a mais mal explicada. A interpretação honesta e fácil de defender é esta:

Se eu sortear ao acaso uma internação que teve o desfecho e uma que não teve, o ROC-AUC é a probabilidade de o modelo ter dado escore maior para a que teve.

Valores: 0,5 é sorteio de moeda (o modelo não sabe nada). 1,0 é perfeito. **O nosso é 0,731641** no teste fora do tempo de 2024.

Isso é bom? Para reinternação hospitalar, sim, está na faixa esperada. A literatura internacional raramente passa de 0,75 a 0,80 com dado administrativo, porque falta a informação clínica (sinal vital, exame, medicação, gravidade) que mais explica o desfecho. Nossa base é administrativa: ela sabe o diagnóstico e quanto tempo a pessoa ficou, mas não sabe a pressão arterial dela. **Este é o teto do tipo de dado, não falta de tunagem.**

Average Precision (AP) / PR-AUC. Quando os positivos são poucos, o ROC-AUC pode parecer generoso. A curva Precisão-Revocação é mais severa nesse cenário. O nosso **AP é 0,385346**. A régua aqui é a prevalência: um modelo aleatório teria AP igual a 0,1485. Ou seja, estamos **2,6 vezes acima do aleatório** nessa métrica.

Brier score. Mede **calibração**, isto é, se as probabilidades que o modelo cospe são realistas. Se o modelo diz “30% de chance” para mil casos, cerca de 300 deveriam de fato ter o desfecho. O Brier é o erro quadrático médio entre a probabilidade prevista e o que aconteceu. **Menor é melhor.** O nosso é **0,110900**. Para comparação, um modelo que sempre chutasse a prevalência (0,1485) teria Brier de aproximadamente 0,1264. Estamos melhor que isso.

Lift. A métrica mais fácil de explicar para um gestor e a que usamos no pitch. Lift responde: “no grupo que o modelo colocou no topo, o desfecho é quantas vezes mais frequente que na média?”.

O nosso lift no top 10% é **3,079179**. A conta é direta: 45,7205% dividido por 14,8483% dá 3,08.

A frase exata que deve ser dita, e a que não deve:

- ✓ Correto: “No grupo formado pelos 10% de maior escore, 45,7205% das internações apresentaram o desfecho no teste fora do tempo de 2024; no conjunto completo foram 14,8483%.”
- ✗ Errado: “O top 10% capturou 45,72% de todos os positivos.” Isso é **outra métrica** (recall no top 10%) e teria outro valor.
- ✗ Errado: “O modelo reduz reinternação em 3 vezes.” O modelo **não reduz nada**. Ele ordena.

1.6 Vazamento de dados (data leakage)

Esse conceito merece seção própria porque é o coração do nosso maior diferencial.

Definição. Vazamento é quando informação que **não estaria disponível no momento da decisão** entra no treino do modelo. O sintoma clássico é um resultado bom demais.

Analogia. É como um professor que, sem perceber, deixou o gabarito impresso no verso da folha de prova. O aluno gabarita, mas não porque aprendeu.

Tipos: - **Vazamento temporal:** usar informação do futuro para prever o passado. - **Vazamento por construção (tautologia):** quando a feature contém a resposta por definição, não por aprendizado. - **Vazamento por identidade:** quando o modelo reconhece a pessoa em vez de aprender o padrão.

Nós tivemos o segundo tipo, descobrimos e corrigimos. A Parte 7 conta a história inteira, e é a parte do caderno que vocês devem saber contar de cor.

1.7 Privacidade e os conceitos de proteção

Dado pessoal. Qualquer informação que identifique ou possa identificar uma pessoa.

Quase-identificador. Um campo que sozinho não identifica ninguém, mas **em combinação** identifica. Sexo sozinho não identifica. Sexo + faixa etária + município + mês + diagnóstico pode identificar uma pessoa só. Foi exatamente isso que medimos na nossa auditoria.

Anonimização. Tornar impossível (ou razoavelmente impossível) ligar o dado a uma pessoa. A LGPD, no Art. 12, diz que dado efetivamente anonimizado **sai do escopo da lei**.

Pseudonimização. Substituir o identificador por um código, mantendo a possibilidade de religar com uma chave separada. A LGPD trata disso no Art. 13, no contexto de estudos em saúde pública.

k-anonimato. O conceito central da nossa governança. Um conjunto de dados é k-anônimo quando **cada combinação de quase-identificadores aparece em pelo menos k registros**. Com $k = 5$, qualquer recorte publicado tem no mínimo cinco interações atrás dele, de modo que a informação não aponta para um indivíduo.

Por que 5, e não 3 ou 10? Esta é uma pergunta provável e a resposta está na Parte 5. Adiantando: cinco é um limiar amplamente usado em divulgação de estatística de saúde, equilibrando proteção e utilidade. **A LGPD não fixa esse número.** Dizer que a lei exige $k=5$ é um erro factual que a banca pode cobrar.

Ataque por diferença. Um risco real: se eu consigo ver o total do estado e o total de todos os municípios menos um, eu descubro o município que falta por subtração. É por isso que a nossa view de polo **não** está exposta ao NL2SQL livre, e sim usada internamente pela função controlada.

1.8 Os conceitos de IA generativa que usamos

LLM (Large Language Model). Um modelo treinado para prever a próxima palavra, que como efeito colateral aprende a escrever, resumir e traduzir linguagem para outros formatos. É o que está por trás do ChatGPT e, no nosso caso, do Cohere dentro do Select AI.

Alucinação. Quando o LLM produz uma afirmação plausível e falsa. É o risco número um de usar IA generativa em saúde. Todo o desenho do CLARITI existe para tornar a alucinação **estruturalmente**

impossível nos números.

NL2SQL (Natural Language to SQL). Traduzir uma pergunta em português para uma consulta SQL. O LLM não vê o dado: ele vê os **metadados** (nomes de tabela, nomes de coluna, comentários) e escreve a consulta. Quem executa é o banco.

Select AI. O recurso do Oracle Autonomous Database que faz NL2SQL. Você configura um **perfil** dizendo quais objetos o LLM pode enxergar, e ele passa a aceitar perguntas em linguagem natural.

SHOWSQL . Um modo do Select AI que **mostra o SQL gerado sem executá-lo**. É o que nos permitiu revisar cada consulta antes de rodar. Foi assim que pegamos, por exemplo, um filtro escrito como `FX_IDADE='65 a 69 anos'` quando o valor real na base é `65-69` .

OML4Py (Oracle Machine Learning for Python). A biblioteca que permite escrever Python que treina modelos **dentro** do banco. Você escreve código que parece pandas e scikit-learn, mas o processamento acontece no servidor Oracle e o dado nunca sai.

AI Agent. Um orquestrador. Ele recebe a pergunta, decide qual **ferramenta** chamar, chama, recebe o resultado e escreve a resposta em linguagem natural. No Oracle isso é o pacote `DBMS_CLOUD_AI_AGENT` , com objetos Agent, Task, Tool e Team.

Tool (ferramenta). Uma capacidade registrada que o Agent pode acionar. No CLARITI, cada Tool aponta para uma função PL/SQL determinística. Isso é a chave da governança: **o Agent não escreve o número, ele narra o número que a função devolveu**.

Zero Data Movement. O princípio arquitetural de processar o dado onde ele está, em vez de copiá-lo para fora. Menos cópias significa menor superfície de risco, menos custo e menos inconsistência. No CLARITI: o dado fica no Oracle, o modelo treina no Oracle, a regra de privacidade é aplicada no Oracle, e o que sai é resultado agregado.

Ressalva que vocês devem dizer antes que a banca pergunte: o Select AI envia a **pergunta e os metadados autorizados** para o provedor do LLM. Não envia dado de paciente. Então a formulação honesta é “zero data movement para o dado”, não “zero data movement absoluto”. Se alguém apertar, a alternativa para o literal seria remover o LLM externo e manter só OML4Py e SQL.

PARTE 2 — A ARQUITETURA, CAMADA POR CAMADA

2.1 O desenho em uma frase

O dado público entra no Oracle, é transformado em produtos analíticos agregados, o modelo é treinado dentro do próprio banco, a política de privacidade é aplicada no motor relacional, e a IA generativa só narra o que a barreira determinística autorizou.

2.2 As sete camadas

Camada 1 — Fontes públicas. SIH/SUS (internações), CNES (leitos), SIOPS (gasto), SIA (atendimento ambulatorial), IBGE (população). Todas públicas, todas nacionais, nenhuma com dado pessoal identificado.

Camada 2 — Preparação. Scripts Python que baixam, limpam, classificam CSAP, calculam reinternação e montam as tabelas analíticas. Roda fora do Oracle, na fase de construção da base.

Camada 3 — Base no Oracle. A tabela granular `TB_PERFIL_PRINCIPAL_V2`, com 813.422 internações. Ela é a fonte de tudo, e **nunca é exposta**.

Camada 4 — Produtos analíticos (as views k=5). Cinco visões agregadas, todas com supressão de células pequenas. São a única coisa que o NL2SQL enxerga.

Camada 5 — Modelo (OML4Py). XGBoost treinado in-database. O modelo persistido é `CLARITI_REINT_FULL_FINAL_V1`. Os escores ficam numa tabela com 759.402 internações.

Camada 6 — Barreira determinística (funções PL/SQL). Funções que recebem parâmetros, consultam as views, aplicam k=5, executam o fallback e devolvem JSON publicável.

Camada 7 — IA e aplicação. Select AI para NL2SQL sobre as views, AI Agent (a Athena) com sete Tools, e a aplicação web consumindo por ORDS.

2.3 Por que essa ordem importa

A pergunta que a banca pode fazer é: “por que não deixar o LLM consultar a base direto?”. A resposta tem três camadas:

1. **Privacidade.** A tabela granular tem 65,3% das linhas com combinação única de quase-identificadores. Expor isso ao NL2SQL seria expor um risco de reidentificação alto.
2. **Correção.** LLM erra SQL. Nós vimos isso acontecer: numa das rodadas, o Agent filtrou `IN_CSAP='UTI'` e reagregou uma view já agregada, produzindo um zero falso. Se o número saísse direto do LLM, esse zero teria virado resposta.
3. **Auditabilidade.** Com função determinística, qualquer número pode ser reproduzido rodando a mesma função com os mesmos parâmetros. Com LLM no caminho do número, não pode.

2.4 As cinco views publicáveis

O perfil do Select AI (`CLARITI_SAFE_PROFILE`) tem `enforce_object_list = true` e exatamente cinco objetos:

View	O que agrega	Granularidade
VW_PAINEL_MUN_ANO_PUBLICO_K5	painel municipal público	município × ano
VW_REINT_MUN_ANO_FAIXA_GRUPO_K5	reinternação municipal	município × ano × faixa etária × grupo CSAP
VW_REINT_SP_ANO_FAIXA_GRUPO_K5	referência estadual	estado × ano × faixa × grupo
VW_DIAG_MUN_ANO_K5	perfil diagnóstico	município × ano × CID principal
VW_SAZONAL_SP_MES_GRUPO_K5	sazonalidade	estado × mês × grupo CSAP

O que NÃO está no perfil, por decisão explícita: a tabela individual, a view de polo (usada só internamente pelo fallback), identificador de internação, idade exata, diagnóstico individual, mês e sexo em combinação livre.

2.5 As sete ferramentas da Athena

Tool	Função por trás	Para que serve
CLARITI_SQL_SEGURO	Select AI sobre as 5 views	rankings e consultas agregadas autorizadas
CLARITI_REINT_K5_TOOL	FN_CONSULTA_REINT_GESTOR_K5	reinternação municipal com k=5 e fallback
CLARITI_DIAG_K5_TOOL	FN_TOP_DIAG_GESTOR_K5	top diagnósticos com CID-10 oficial
CLARITI_SAZONAL_K5_TOOL	FN_SAZONAL_GESTOR_K5	padrão sazonal por grupo CSAP
CLARITI_ML_PRIORIZACAO_TOOL	FN_PRIORIZACAO_ML_GESTOR	resultado oficial do modelo (top 10%, lift)
CLARITI_ML_IMPORTANCIA_TOOL	função de importância	explicabilidade global do modelo
CLARITI_SOLUCOES_GESTOR_TOOL	catálogo governado	alternativas gerenciais e indicadores

Objetos do Agent: Team `CLARITI_GESTOR_TEAM` , Task `CLARITI_GESTOR_TASK` , Agent `CLARITI_GESTOR_AGENT` , processo sequencial.

PARTE 3 — OS DADOS: DE ONDE VIERAM E O QUE VIRARAM

3.1 O recorte

Território: 645 municípios de São Paulo. **Período:** 2022 a 2024, com admissões residuais de 2021 preservadas apenas para conseguir calcular histórico e reinternação de quem foi internado em janeiro

de 2022. **Filtro clínico:** internações que consumiram UTI.

3.2 Os números que sustentam o pitch

Número	O que é	Onde se confere
813.422	internações com UTI processadas	<code>perfil_paciente_sp_2022_2024.parquet</code> , base no Oracle
805.118	dessas, com residência mapeada na malha de SP (98,98%)	auditoria de escopo do gate Q4
8.304	sem correspondência na malha (1,02%), mantidas na base e no OML, fora da view municipal	idem
152.069	internações classificadas como ICSAP (18,69% do total)	recorte CSAP
19	grupos CSAP distintos	classificação oficial
759.402	internações com escore do modelo no Oracle	tabela de scores
248.507	internações no teste fora do tempo de 2024	avaliação final
1.599	códigos CID-10 distintos usados pelo CLARITI	gate do dicionário
14.233	códigos no dicionário CID-10 carregado	<code>TB_CID10_REFERENCIA</code>

Atenção a uma divergência interna que vocês precisam conhecer. Documentos anteriores do projeto citam outras contagens de população do modelo (por exemplo 783.860 elegíveis, 516.286 de treino, 267.574 de teste). Esses números vêm de **rodadas locais anteriores**, em pandas, com filtros diferentes. **A versão vigente, e a única que deve ser dita na banca, é a do OML4Py no Oracle**, homologada em 14/09: 759.402 escorados, 248.507 no teste de 2024. Se alguém apontar a diferença, a resposta honesta é: “são rodadas distintas; a rodada local foi a exploratória, a rodada in-database é a oficial, e a diferença está nos filtros de elegibilidade documentados.”

3.3 A chave de paciente, e por que ela é aproximada

A base pública **não tem CPF nem qualquer identificador de pessoa**, por design. Mas para calcular reinternação é preciso saber que duas internações são da mesma pessoa.

O que fizemos: montamos uma chave combinando **data de nascimento + sexo + CEP**. Se duas internações têm a mesma combinação, tratamos como a mesma pessoa.

Como isso é tratado com cuidado: - A chave é montada **em memória**, durante a execução do script, e **descartada**. Nunca é salva, nunca é exposta. - Marcamos as combinações suspeitas de colisão (duas pessoas diferentes com a mesma combinação) numa flag: `chave_colisao_suspeita`. - **3.059 linhas** (0,38% da base) foram marcadas, sendo **385 dentro do recorte ICSAP**. - Nas análises de vínculo entre internações, essas linhas são excluídas. Nas análises descritivas (diagnóstico, valor, permanência), elas permanecem, porque a colisão afeta o vínculo entre internações e não invalida o diagnóstico daquela admissão.

A frase para a banca: “A ligação é aproximada, nós medimos o quanto ela é aproximada, e preservamos essa limitação na interpretação.”

3.4 O achado que abre o pitch, dito com precisão

A tese inicial era: município que investe mais em atenção primária tem menos internação evitável em UTI.

O que encontramos: - SIOPS por subfunção Atenção Básica: Spearman **+0,206** sem defasagem e **+0,204** com defasagem de um ano, N = 642 municípios, cobertura 99,3%. A hipótese original não foi confirmada (p = 1,0) e o pós-teste na direção oposta deu p < 0,00001. - Cobertura real de UBS via SIA: Spearman **+0,162** (sem defasagem, N = 548) e **+0,180** (com defasagem, N = 505). Mesma direção. - PSM municipal: ATT = 0,453, **p = 0,5513, não significativo**, e o sinal inverte sem reposição no pareamento.

Como isso deve ser dito:

✓ “Nos dados que analisamos, a relação simples não se confirmou.” ✗ “Investimento em saúde não reduz internação evitável.”

Por quê. Correlação positiva entre gasto e internação evitável tem uma explicação concorrente muito mais provável que “gastar piora”: **causalidade reversa**. Município com mais casos recebe e aloca mais recurso. Além disso, o PSM, que era a tentativa de aproximar causalidade, **não encontrou efeito**. Ausência de evidência não é evidência de ausência.

Este é o ponto mais atacável do pitch. A defesa está na Parte 9, pergunta 1.

3.5 Sazonalidade

O achado: entre os 19 grupos CSAP, 11 mostram sazonalidade estatisticamente significativa. O maior é **Asma**, com amplitude de **113,95%**, pico em **agosto** (608 internações) e mínimo em **janeiro** (190). Total histórico do grupo: 4.402, média mensal 366,83.

Como a amplitude é calculada, exatamente: $100 \times (\text{máximo mensal} - \text{mínimo mensal}) / \text{média das 12 contagens}$. Sem ajuste pelo número de dias do mês e sem mediana entre anos.

Atenção a uma confusão fácil: “pico acima da média” é **outra conta**, e para a asma dá **65,74%**, não 113,95%. Se a banca perguntar “amplitude de quê?”, a resposta é a fórmula acima.

Teste global: qui-quadrado de independência 19×12 , $\chi^2 = 1.434,15$, $p = 3,26e-186$, V de Cramér = 0,029 (efeito fraco em média, o que é esperado, já que a sazonalidade é forte em alguns grupos e nula em outros).

Limites a declarar: é padrão histórico descritivo, não previsão; a série inclui 2.872 internações ICSAP iniciadas em 2021; não há ajuste por dias do mês.

PARTE 4 — O MODELO: CADA DECISÃO E O PORQUÊ

4.1 A pergunta que o modelo responde

Formulação exata: dada uma internação com UTI que já terminou, qual a probabilidade de que ela tenha sido seguida por um retorno à UTI em até 30 dias?

Leia de novo a frase acima e note o tempo verbal. É **retrospectiva**. O modelo classifica um evento que já aconteceu no histórico, usando informação que só está completa **depois** da alta.

Por que isso importa tanto. Duas das nossas features (`QT_DIAS_PERM` , dias de permanência, e `VL_TOT` , valor total) **não existem no momento da admissão**. Elas só ficam completas quando a internação acaba. Portanto o modelo, como está, não pode ser usado para pontuar um paciente que acabou de dar entrada.

A frase correta para a banca: “É uma classificação retrospectiva de reinternação em 30 dias, com treino em 2022–2023 e teste fora do tempo em 2024. Não é previsão clínica prospectiva.”

Se perguntarem como virar prospectivo: seria outro produto. Exigiria mudar o marco de previsão (pontuar na admissão ou na alta), redefinir o alvo, usar só features disponíveis naquele instante, e validar de novo. Não é um ajuste, é um novo ciclo.

4.2 A definição exata do alvo

`reinternacao_30d` marca a internação atual quando a **admissão** dela cai entre zero e 30 dias após a **alta estimada** da internação anterior da mesma chave de paciente.

Alta estimada = data de admissão + dias de permanência.

Por que “estimada”? Porque a base traz a data de admissão e a quantidade de dias, e nós reconstruímos a alta somando. É uma reconstrução, não um campo original.

4.3 As features e o que cada uma significa

Por importância global (percentual do GAIN no modelo full):

#	Feature	O que é	% GAIN
1	QT_INTERNAcoes_365D_PREVIAS	quantas internações da mesma chave nos 365 dias anteriores	25,83%
2	QT_UTI_MES	diárias de UTI consumidas	22,61%
3	QT_DIAS_PERM	dias de permanência	21,53%
4	CD_DIAG_PRINC	código do diagnóstico principal	16,85%
5	VL_DISTANCIA_POLO_KM	distância ao polo regional	6,78%

O que é GAIN. Quando o XGBoost decide abrir uma bifurcação na árvore usando uma variável, ele calcula quanto aquela divisão melhorou o modelo. GAIN é a soma dessas melhorias por variável. Em palavras: **quanto aquela variável ajudou a separar os casos.**

O que GAIN NÃO diz, e isso é pergunta de banca: - Não diz a **direção**. GAIN alto não significa “mais disso, mais risco”. - Não diz **causalidade**. Distância ao polo aparecer na lista não significa que a distância causa reinternação. - Não é o mesmo que SHAP, que decompõe a contribuição por predição individual.

4.4 As métricas finais, com a régua de comparação

Teste fora do tempo, 2024, modelo CLARITI_REINT_FULL_FINAL_V1 :

Métrica	Valor	Régua de comparação	Leitura
Internações avaliadas	248.507	—	nenhuma participou do treino
Positivos	36.899	—	prevalência de 14,8483%
ROC-AUC	0,731641	0,5 = aleatório; literatura de reinternação raramente passa de 0,75–0,80 com dado administrativo	discriminação boa para o tipo de dado
Average Precision	0,385346	aleatório seria 0,1485	~2,6× acima do aleatório
Brier	0,110900	chute na prevalência daria ~0,1264	calibração melhor que o chute
Lift top 10%	3,079179	1,0 = nenhuma capacidade de ordenar	grupo com desfecho 3,08× mais frequente
Positivos no top 10%	45,7205%	14,8483% no conjunto	o número do pitch

4.5 Por que treino em 2022–2023 e teste em 2024

Três razões, em ordem de força:

1. **Simula o uso real.** Modelo em produção pontua o futuro.
2. **Testa estabilidade temporal.** Se a rede mudar de comportamento, aparece. Sorteio aleatório esconde isso.
3. **Evita vazamento temporal.** Sem chance de o modelo ter visto no treino um caso que informa o teste.

4.6 A comparação baseline versus full

Treinamos **dois** modelos para poder medir o ganho incremental de uma ideia específica.

- **Baseline:** só as informações da própria internação.
- **Full:** o mesmo, mais o **histórico de internações prévias** da mesma chave.

O ganho do histórico, medido no subconjunto onde ele faz sentido (quem tem pelo menos uma internação prévia), ficou entre **+0,03 e +0,05 de AUC** conforme a rodada, com intervalo de confiança de 95% que **não cruza zero** em 2.000 reamostragens bootstrap. É um ganho pequeno, real e estatisticamente sólido.

Nota de honestidade que vocês devem conhecer: rodadas locais diferentes deram 0,6582/0,6927 (A7) e 0,6554/0,6943 (A13). A causa exata da diferença entre as rodadas **não foi isolada**. A rodada oficial é a do Oracle. Se a banca apontar a divergência, diga exatamente isso.

4.7 O que é bootstrap, já que ele aparece na defesa

Você tem um resultado e quer saber se ele é real ou sorte. Bootstrap é: sortear, com reposição, uma amostra do mesmo tamanho a partir dos seus dados, recalculando a métrica, e repetir isso milhares de vezes. Você obtém uma distribuição da métrica. Se o intervalo que contém 95% dessa distribuição **não inclui zero**, o efeito é consistente.

Fizemos 2.000 reamostragens. O IC 95% do ganho foi [+0,0303; +0,0385] na rodada A7 e [+0,0347; +0,0430] na A13.

Limite a declarar: o bootstrap foi de **linhas**, não de pessoas. Ele não controla a dependência entre internações do mesmo paciente. É uma limitação conhecida e documentada.

PARTE 5 — A GOVERNANÇA: k=5, FALLBACK E POR QUÊ

5.1 O problema real que motivou tudo

Antes de escolher qualquer proteção, nós **medimos** o risco. O script

`Auditoria_Reidentificacao.py` rodou nas três tabelas finais e o resultado foi:

- Na tabela individual (813.422 linhas), a combinação `faixa etária × sexo × município × mês × diagnóstico` é **única em 531.051 linhas, ou 65,3% da base**.
- Na tabela `dataset_unificado` (`município × mês × diagnóstico`), **95,4% das linhas têm contagem menor que 5** e 77,3% têm contagem exatamente 1.
- No painel `município × ano`, 13,75% das linhas têm contagem menor que 5, sendo 41 linhas com contagem exatamente 1, todas em municípios com menos de 20 mil habitantes.

Tradução: dois terços da base individual são combinações únicas. Publicar esse nível de detalhe seria publicar um caminho de reidentificação. **O risco era alto, e nós descobrimos isso medindo, não supondo.**

5.2 Por que a resposta não foi “hashear mais campos”

Houve uma ideia anterior no projeto, de pseudonimizar mais campos com hash. Ela foi **abandonada**, e o motivo é instrutivo:

O risco não está em nenhum campo isolado. Está na **combinação**. Hash de campo individual não muda a unicidade da combinação, porque a combinação de campos hashados continua igualmente única. O controle tem que estar **na consulta**, não na coluna.

Essa é uma das melhores respostas que vocês podem dar numa arguição, porque mostra que a equipe entendeu o mecanismo do risco.

5.3 O que é k=5, na prática do CLARITI

A regra: resultado clínico só é publicado quando a célula tem pelo menos cinco interações.

Onde a regra mora: dentro das views, na cláusula `HAVING COUNT(*) >= 5`, aplicada **antes** de qualquer enriquecimento. Isto é, a agregação e o corte acontecem primeiro; só depois o resultado é enriquecido com descrição de CID e devolvido.

Por que “no banco” é diferente de “na aplicação”: se a regra estivesse no código da aplicação, bastaria alguém consultar o banco por outro caminho para burlá-la. Estando na view e na função, toda consulta autorizada já vem filtrada.

5.4 Por que 5

A resposta de três partes:

1. **k = 5 é um limiar usual** na divulgação de estatísticas de saúde e uma escolha de proporcionalidade: k pequeno demais não protege, k grande demais inutiliza o produto para municípios pequenos.
2. **É política do projeto, não exigência legal.** A LGPD estabelece o **dever** de proteção; ela não fixa o número. Dizer “a LGPD exige k=5” é um erro factual.

3. **É uma redução de risco, não uma garantia.** Cinco registros não garantem cinco pessoas distintas, e k-anonimato não elimina ataque por diferença nem inferência.

A frase aprovada: “k=5 é uma política de proteção proporcional para divulgação de dados de saúde. A LGPD não fixa esse número; ele não é uma regra legal literal.”

5.5 O fallback hierárquico, que é o diferencial

O problema com uma proteção simples: se o sistema apenas recusar quando o recorte é pequeno, o gestor fica sem resposta. Proteção que quebra o produto vira obstáculo, e na prática as pessoas contornam.

Nossa solução: quando o recorte pedido não atinge k=5, a função **sobe um nível territorial** e publica o primeiro nível seguro. A hierarquia é **município** → **polo regional** → **estado**.

O caso homologado, que é o que vai ao palco: - Pedido: Altinópolis, 2023, faixa 60–69 anos, grupo CSAP Insuficiência cardíaca. - Internamente, a função encontrou **4 internações**. Abaixo de k=5. - A contagem 4 **não aparece** em nenhum lugar do retorno. - A função devolveu `FALLBACK_SEGURO` e publicou o polo de **Ribeirão Preto**: 226 internações, 30 reinternações, taxa de 13,27%, referência estadual 11,97%, diferença de +1,3 ponto percentual, com o investimento em Atenção Básica do ano anterior de R\$ 485,22 por habitante.

Regra absoluta para o palco: nunca revelar a contagem suprimida. Se alguém da banca perguntar “quantos eram?”, a resposta é: “o produto não publica esse número, é exatamente o que a política impede”.

5.6 Por que a view de polo está fora do NL2SQL

Porque expor município, polo e estado simultaneamente ao SQL livre facilitaria **ataque por diferença**: com os totais de níveis sobrepostos, é possível deduzir por subtração a célula suprimida. A view de polo existe, mas só a função controlada a usa, e só para executar o fallback.

Esse é um detalhe de desenho que quase nenhum trabalho de graduação tem. Vale mencionar.

5.7 Os dois regimes de LGPD

O projeto opera em dois regimes diferentes, e confundi-los é erro:

Onde	Regime	Base legal	O que significa
No produto (o que o gestor vê)	anonimizado + k=5	Art. 12	dado efetivamente anonimizado sai do escopo da LGPD
No pipeline (treino do modelo)	chave aproximada em memória, nunca persistida	Art. 13 (pesquisa em saúde pública)	a chave existe só durante a execução e é descartada

A frase: “Anonimizado no produto, privacy-preserving no pipeline.”

PARTE 6 — A CAMADA DE IA: SELECT AI, AGENT E AS SETE FERRAMENTAS

6.1 Os três papéis, que não se confundem

Tecnologia	O que faz	O que NÃO faz
Select AI	traduz pergunta em português para SQL sobre as views autorizadas	não vê dado de paciente, não decide o número
OML4Py	treina e aplica o modelo dentro do banco	não conversa, não interpreta
AI Agent (Athena)	escolhe a ferramenta, chama, recebe JSON e narra	não calcula nada

A frase de arquitetura aprovada: “O CLARITI descreve o passado com Select AI, estima risco com OML4Py e traduz os resultados em orientação gerencial governada com AI Agent.”

6.2 Como o Select AI funciona, passo a passo

1. O gestor escreve a pergunta em português.
2. O Oracle envia **a pergunta e os metadados** dos objetos autorizados (nomes de view, nomes de coluna, comentários) para o provedor de LLM.
3. O LLM devolve um SQL.
4. **O Oracle executa o SQL**, respeitando as permissões do perfil.
5. O resultado volta.

O ponto de governança: o `object_list` do perfil `CLARITI_SAFE_PROFILE` tem `enforce_object_list = true` e exatamente cinco views. O LLM **não sabe que a tabela individual existe**.

O papel dos `COMMENT ON`: nomes de coluna crus como `uti_mes_to` e `val_tot` são hostis ao NL2SQL, porque o LLM não adivinha o significado. Nós adicionamos comentários descritivos nas views, e são esses comentários que o LLM lê. Isso é uma decisão de engenharia que melhora a taxa de acerto.

6.3 As cinco consultas NL2SQL homologadas

A rubrica do Challenge exige no mínimo três consultas `SELECT AI SHOWSQL`, cada uma com prompt, SQL gerado, resultado, insight e recomendação. Nós documentamos **cinco**.

#	Pergunta	Resultado
Q1	reinternação estadual por faixa e grupo	base 1.614, 189 reinternações, taxa 11,71%, AB anterior R\$ 524,43/hab

#	Pergunta	Resultado
Q2	prioridade territorial por taxa ICSAP em 2024	Lutécia 592,81; Santa Clara d'Oeste 560,33; Colina 551,96 (104 internações, 18.842 hab); Ubarana 549,85; Timburi 522,09
Q3	maior piora 2023 → 2024	Timburi +319,17; Guaíra +308,96; Poloni +276,98; Santa Clara d'Oeste +252,40; Santa Cruz do Rio Pardo +214,48
Q4	top 5 diagnósticos de Colina em 2024	A41.9 (14), N39.0 (12), I21.9 (11), I64 (10), J15.9 (10); juntos 57 internações e 18,29%
Q5	sazonalidade da Asma	agosto, 608, total 4.402, média 366,83, amplitude 113,95%

O insight transversal da Q2, que é bom dizer: os maiores valores de taxa aparecem sobretudo em municípios pequenos, onde o denominador é pequeno e a taxa é instável. Por isso mostramos **sempre taxa junto com contagem e população**. E a frase de rigor: “k=5 protege a divulgação, mas não garante estabilidade estatística.”

6.4 O processo de homologação, que é o diferencial invisível

Nenhuma dessas consultas foi aceita de primeira. O procedimento foi sempre: gerar com `SHOWSQL`, ler o `SQL`, aprovar ou recusar, e só então executar.

Exemplos reais de recusas: - **Q1, tentativa 1:** o SQL filtrou `FX_IDADE='65 a 69 anos'`, mas o valor real na base é `65-69`. Não executamos; refinamos o prompt informando o rótulo humano e a codificação real. - **Q2, tentativa 1:** faltaram `IS NOT NULL` e `NULLS LAST`. Sem isso, um `ORDER BY DESC` traria células mascaradas no topo. Não executamos. - **Q4, tentativa 1:** SQL semanticamente correto, mas sem desempate determinístico entre CIDs de mesma contagem. Refinamos para ordenar por quantidade decrescente e CID crescente.

A frase para a banca: “Nós não confiamos no SQL que o LLM escreve. Nós lemos cada um antes de executar, e três dos cinco foram recusados na primeira tentativa.”

6.5 O Agent, e as quatro reprovações de QA

O Agent foi homologado depois de ser **reprovado quatro vezes** em revisão de qualidade. Cada reprovação e sua correção:

1. **Extrapolção de “qualidade do cuidado”.** O Agent inferiu julgamento de qualidade a partir de uma taxa. Corrigimos a Task para restringir aos conceitos que a Tool efetivamente retorna.
2. **A419 narrado como CSAP, e descrições de CID vindas da memória do LLM.** Isso motivou o requisito do dicionário oficial.
3. **Zero falso.** O SQL do Agent filtrou `IN_CSAP='UTI'` e reagregou uma view já agregada com `COUNT(*)/HAVING>=5`, produzindo zero onde havia 11 células. Diagnosticamos lendo o

histórico do Agent e substituímos por uma função JSON determinística.

4. **Cálculo novo.** O Agent calculou “3,2 vezes”, métrica que a Tool não retornava. Proibimos explicitamente qualquer cálculo novo na narrativa.

Por que contar isso é bom e não ruim: mostra que existe um processo de QA, que ele pega erro real, e que a equipe não aceitou a primeira resposta bonita. Um trabalho que nunca reprovou nada provavelmente nunca olhou.

6.6 O dicionário CID-10, e por que ele virou requisito

O problema: antes, a Tool devolvia apenas `A419`, `N390`, `I219`. A Athena tinha instrução explícita de escrever “descrição CID indisponível” em vez de completar por memória. Isso evitava alucinação, mas deixava a demonstração ilegível para um gestor.

A solução: carregar o dicionário oficial dentro do Oracle.

- Fonte: **CID-10 DATASUS V2008**, pt-BR, do Centro Brasileiro de Classificação de Doenças.
- O servidor do DATASUS recusou a transferência automatizada; os mesmos arquivos foram obtidos em espelho público, e essa contingência está registrada no banco e no QA. **Nenhuma descrição foi montada à mão.**
- Foi preciso combinar dois arquivos: o de subcategorias sozinho cobria 1.528 dos 1.599 códigos (95,56%); os 71 faltantes eram códigos de três caracteres, que existem como categoria. Unimos, acrescentando só o que faltava.
- Resultado: **14.233 códigos únicos**, cobertura de **1.599/1.599 (100%)** dos CIDs usados pelo CLARITI, zero descrição nula, zero caractere substituto, zero código inválido, zero duplicidade.

A frase de produto, aprovada: “O modelo de linguagem não traduz códigos clínicos por memória. Ele narra o dicionário oficial que o banco devolve.”

6.7 Estabilidade da narrativa, e a decisão de parar de apertar

A Athena varia a redação entre execuções. Isso é da natureza de um LLM. A decisão registrada foi: **aceitar a variação de redação desde que fatos, unidade, fonte e limites sejam preservados**, e parar de apertar o prompt só para obter frases idênticas.

O desenho que sustenta essa decisão: a **Tool** fornece o contrato determinístico, a **Athena** fornece a narrativa governada. Para a demonstração, mantém-se uma execução previamente carregada ou gravada como contingência.

Tempo de resposta medido: `RUN_TEAM` homologado em 16,092 segundos direto no Oracle (18,813 s antes do refinamento). Esse tempo é do banco; pela aplicação publicada o caminho é mais longo.

PARTE 7 — OS ERROS QUE ENCONTRAMOS E CORRIGIMOS

Esta é a parte mais valiosa do caderno. Se a banca der abertura, **conte a história do erro número 1**. Ela demonstra maturidade metodológica melhor que qualquer métrica.

7.1 A tautologia da feature de histórico

O que aconteceu. Treinamos o modelo com uma feature de contagem de internações anteriores e obtivemos **ROC-AUC de 0,9793**.

Por que isso foi tratado como problema, e não como vitória. Reinternação hospitalar é um problema notoriamente difícil. A literatura raramente passa de 0,75–0,80. Um 0,98 não é sinal de genialidade, é sinal de que **algo vazou**. O absurdo do resultado foi o gatilho para reabrir a investigação em vez de aceitar o número.

Rodada 1 do diagnóstico. A feature original era uma contagem vitalícia (`cumcount`). Descobrimos que 79% das linhas tinham `cumcount == 0`, ou seja, era a primeira internação daquela pessoa **na base inteira**, e 0% dessas tinham reinternação. Não porque o modelo aprendeu: porque sem internação anterior é impossível haver “reinternação”. Trocamos por uma janela móvel de 365 dias.

Rodada 2, e o erro que ninguém viu. Com a janela de 365 dias, verificamos o “bolso” lógico que precisaria existir para quebrar a lógica e encontramos zero casos. Parecia resolvido. **Mas ninguém, nem nós, nem a revisão cruzada com outro modelo, parou para notar que 30 dias é subconjunto de 365 dias.** Se a pessoa não teve nenhuma internação nos últimos 365 dias, é impossível ter tido uma nos últimos 30. Mesma estrutura de tautologia, agora cobrindo **80,17% das linhas** (649.696 de 810.363 válidas, com 0,0000% de positivos).

Como medimos o que é real. Restringindo a avaliação a quem **tem** pelo menos uma internação prévia, onde a garantia lógica não vale. Nesse recorte, o ganho do histórico é de +0,0345 a +0,0389 de AUC, com IC 95% que não cruza zero em 2.000 reamostragens.

Teste adicional contra memorização. Separamos pacientes cuja chave apareceu no treino dos que só apareceram em 2024. O ganho foi **+0,0450 em pacientes nunca vistos** e +0,0576 em pacientes vistos. Os dois positivos e de magnitude parecida, o que indica que o sinal **generaliza**, não é reconhecimento de identidade.

Confirmação visual. O gráfico SHAP no teste inteiro mostrava a feature de histórico dominando tudo, com valores de -10 a +3 e todas as outras espremidas em zero: a tautologia aparecendo visualmente. Geramos um segundo SHAP restrito a quem tem histórico, onde a feature ainda lidera mas em escala razoável (+2 a +4) e as demais aparecem com contribuição plausível. **É esse segundo gráfico que vai à banca.**

A lição generalizável, que vale dizer em voz alta:

Uma feature de janela temporal só é segura se a janela **não contiver** o horizonte do alvo. Quando a janela é maior ou igual ao horizonte, o “zero” da feature carrega informação garantida sobre o alvo por definição, não por aprendizado.

Nuance registrada na reconciliação A13, para não exagerar: a janela usa **admissões** e o alvo usa **alta**, então a frase “30 é subconjunto de 365, logo matematicamente impossível” não é universal. **Nesta base**, o atalho foi registrado nos casos sem histórico, e a avaliação restrita o reduz sem eliminar toda a relação retrospectiva entre feature e alvo.

7.2 O overclaim do PSM

A seção do notebook sobre Propensity Score Matching estava redigida de forma mais forte que o resultado sustentava. O resultado real: ATT = 0,453, **p = 0,5513**, e o sinal inverte sem reposição. Ou seja, **não confirmou nada**. A redação foi corrigida.

7.3 A hipótese da idade que não se sustentou

Havia uma hipótese de que idade amplificaria a sazonalidade da insuficiência cardíaca. Rodamos o teste: 60+ tem amplitude de 31,2% e menores de 60 têm 28,3%. Praticamente igual. **É prevalência, não vulnerabilidade sazonal extra do idoso**. A hipótese foi descartada.

7.4 O grupo que quase ficou de fora

A rodada descritiva inicial da sazonalidade olhou apenas os 8 maiores grupos e **perdeu a Asma**, que é justamente o maior achado do conjunto (amplitude 113,95%). Ao rodar os 19, ela apareceu.

A lição: filtrar por volume antes de testar pode esconder o efeito mais forte, porque efeito forte e volume alto são coisas diferentes.

7.5 O erro de fonte que voltou três vezes

A afirmação “o risco dispara após 60 minutos de deslocamento” apareceu três vezes em material externo colado no projeto. Foi testada: a correlação entre tempo e valor SHAP é **-0,632**, negativa e forte. **Não existe esse limiar**. O que sobrevive do eixo distância é a curva de degradação municipal (Spearman rho = 0,1119, p = 0,0045).

PARTE 8 — OS LIMITES: O QUE O CLARITI NÃO FAZ

Decore esta lista. Ela é a sua defesa contra a pergunta que tenta fazer você prometer demais.

O que alguém pode achar	O que é verdade
“O modelo prevê quem vai reinternar”	É classificação retrospectiva . Duas features só existem depois da alta.
“O CLARITI reduz reinternação”	Ele ordena por risco . Redução exigiria intervenção e medição em piloto.

O que alguém pode achar	O que é verdade
"O top 10% captura 45,72% dos positivos"	Isso é outra métrica. O correto: dentro do top 10%, 45,7205% tiveram o desfecho.
"Vocês provaram que investir não adianta"	A relação simples não se confirmou. O PSM não achou efeito ($p = 0,5513$). Causalidade reversa é a explicação líder.
"O CLARITI mostra leitos disponíveis"	Mostra leitos cadastrados no CNES . Disponibilidade real exigiria integração com a operação hospitalar.
"A LGPD exige $k=5$ "	A LGPD estabelece o dever de proteção. O número é política do projeto .
" $k=5$ garante anonimato"	Reduz risco. Não elimina ataque por diferença nem inferência. Cinco registros não garantem cinco pessoas.
"Zero data movement absoluto"	O dado não sai. A pergunta e os metadados vão ao LLM no Select AI.
"Vocês já mediram o efeito do telemonitoramento"	O catálogo apresenta alternativas e define indicadores. Nenhum efeito foi observado .
"O 'Acompanhar' do EPAA já funciona com dado real"	O produto define o que medir . Não há dado de execução de intervenção.
"A sazonalidade prevê agosto de 2025"	É padrão histórico descritivo , sem ajuste por dias do mês, incluindo 2.872 internações iniciadas em 2021.
"A chave identifica o paciente"	É aproximada (nascimento + sexo + CEP), com 3.059 colisões marcadas, e nunca é persistida.
"Marina é uma gestora real que validamos"	É uma persona de demonstração . Nenhum gestor foi entrevistado.

PARTE 9 — PERGUNTAS PROVÁVEIS DA BANCA

Formato: **P** (pergunta) · **R** (resposta) · **SP** (se pressionar).

Bloco A — O achado de abertura

P1. "Vocês provaram que investir em atenção primária não reduz internação evitável?" R. Não. Nós tentamos confirmar essa relação e, nos dados que analisamos, ela não se confirmou. O que encontramos foi correlação positiva (Spearman +0,206 com SIOPS, +0,162 com cobertura real de UBS via SIA), e a explicação líder não é "gastar piora", é **causalidade reversa**: município com mais casos recebe e aloca mais recurso. **SP.** É exatamente por isso que o produto existe. A pergunta interessante deixou de ser "quanto gastar" e passou a ser "onde e quando agir". Além disso, nosso PSM municipal, que era a tentativa de aproximar causalidade, deu ATT = 0,453 com **$p = 0,5513$, não significativo**, e o sinal inverte sem reposição. Nós apresentamos isso como um teste que **não confirmou nada**, não como prova.

P2. “Por que Despesa Liquidada e não Paga?” R. O Anexo 02 do RREO, que é a fonte da abertura por subfunção, não tem coluna de Despesa Paga, só Liquidada. É limitação da fonte e está documentada no próprio nome da coluna.

P3. “Os R\$ 15 bilhões são desperdício?” R. Não afirmamos isso. É o gasto ambulatorial e com internações em hospitais gerais e especializados do SUS no primeiro semestre de 2024, segundo o TCU (Acórdão 738/2025, item 42). Usamos para dimensionar a escala da operação, não para acusar desperdício.

Bloco B — O modelo

P4. “ROC-AUC de 0,73 é bom?” R. Para reinternação hospitalar com dado administrativo, sim, está na faixa esperada. A literatura raramente passa de 0,75 a 0,80, porque falta a informação clínica que mais explica o desfecho: sinal vital, exame, gravidade, medicação. O SIH sabe o diagnóstico e o tempo de permanência, não sabe a pressão arterial do paciente. **É o teto do tipo de dado, não falta de tunagem.** **SP.** As features candidatas óbvias já estão no modelo. O que ainda daria ganho é informação clínica, que essa base não tem. E preferimos reportar 0,73 honesto a reportar 0,98 contaminado, que foi exatamente o que descobrimos e corrigimos.

P5. “Por que XGBoost?” R. Três razões. Primeira: para dado tabular com variáveis heterogêneas e relações não lineares, boosting de árvores é o padrão e costuma superar regressão logística sem exigir especificação manual de interações. Segunda: é **nativo no OML4Py**, o que nos permitiu treinar dentro do Oracle sem exportar a base, que é o princípio arquitetural do projeto. Terceira: rede neural exigiria muito mais dado sem ganho conhecido em tabular deste porte.

P6. “Quais hiperparâmetros vocês usaram? E a regularização?” R. Booster de árvores (`gbtree`), profundidade máxima 6, eta 0,1, 100 rodadas, semente 42, com balanceamento de classes pelo mecanismo nativo do Oracle. A configuração está persistida e é auditável em `USER_MINING_MODEL_SETTINGS`. Para regularização usamos os valores padrão do XGBoost nativo do Oracle: não alteramos `lambda` nem `alpha` explicitamente. **SP.** Regularização L2 (`lambda`) penaliza pesos grandes ao quadrado e evita que o modelo crie regras específicas demais; L1 (`alpha`) tende a zerar pesos e fazer seleção de variáveis. No nosso caso, o controle de sobreajuste veio principalmente de profundidade baixa (6), taxa de aprendizado pequena (0,1) e número moderado de rodadas (100), além do teste fora do tempo, que é o juiz final.

P7. “O que significa Average Precision de 0,385 e Brier de 0,111?” R. AP é a área sob a curva precisão-revocação, mais severa que o ROC quando os positivos são poucos. A régua é a prevalência: um modelo aleatório teria AP de 0,1485, então estamos cerca de 2,6 vezes acima. Brier mede calibração, isto é, se a probabilidade que o modelo cospe é realista; menor é melhor, e um chute fixo na prevalência daria aproximadamente 0,126, pior que os nossos 0,111.

P8. “Por que teste fora do tempo e não validação cruzada aleatória?” R. Porque simula o uso real: um modelo em produção pontua o futuro, não casos sorteados do mesmo período. O teste fora do tempo também expõe degradação se o comportamento da rede mudar entre anos, o que o sorteio aleatório esconde.

P9. “O modelo serve para decidir alta ou internação de um paciente?” R. Não, e isso é importante. É classificação retrospectiva. Duas das features, dias de permanência e valor total, só

ficam completas depois da alta. O modelo não pode pontuar um paciente na admissão. Um produto prospectivo exigiria outro marco de previsão, outro alvo e nova validação.

P10. “Qual a variável mais importante e o que isso significa?” R. Internações prévias em 365 dias, com 25,83% do GAIN, seguida de diárias de UTI (22,61%), dias de permanência (21,53%), diagnóstico principal (16,85%) e distância ao polo (6,78%). GAIN mede o quanto cada variável ajudou a separar os casos. **Não indica direção nem causalidade:** distância ao polo aparecer na lista não significa que a distância cause reinternação.

P11. “Vocês tiveram vazamento de dados?” R. Tivemos, encontramos e corrigimos, e essa é a parte do trabalho de que mais nos orgulhamos. *(Conte a história da Parte 7.1.)* **SP.** O gatilho foi o próprio resultado: 0,9793 de AUC é absurdo para reinternação, e tratamos o absurdo como sintoma, não como conquista. O número honesto é o que apresentamos.

Bloco C — Governança e privacidade

P12. “Vocês usam dado de paciente? Isso não fere a LGPD?” R. São dois regimes. No produto, o que o gestor vê é agregado e anonimizado, com $k=5$, o que se enquadra no Art. 12. No pipeline de treino, usamos uma chave aproximada montada em memória e descartada, nunca persistida, no contexto do Art. 13, que trata de pesquisa em saúde pública. A frase é: anonimizado no produto, privacy-preserving no pipeline.

P13. “Por que $k=5$ e não 3 ou 10?” R. É uma escolha de proporcionalidade: k pequeno não protege, k grande inutiliza o produto para municípios pequenos. Cinco é um limiar usual em divulgação de estatística de saúde. E é importante dizer: **a LGPD não fixa esse número**, ele é política do projeto para apoiar os princípios da lei. **SP.** E $k=5$ reduz risco sem eliminar: cinco registros não garantem cinco pessoas distintas, e k -anonimato não resolve ataque por diferença. Por isso a view de polo fica fora do NL2SQL livre.

P14. “Como vocês sabem que havia risco de reidentificação?” R. Nós medimos. O script de auditoria mostrou que a combinação faixa etária $\times$ sexo $\times$ município $\times$ mês $\times$ diagnóstico é **única em 65,3% da tabela individual**. Não foi suposição.

P15. “Por que não hashear os campos sensíveis?” R. Porque o risco não está no campo isolado, está na combinação. Hash de campo individual não muda a unicidade da combinação. O controle tem que estar na consulta, e é por isso que ele está na view e na função, não na coluna.

P16. “E se eu pedir um recorte muito pequeno?” R. O produto não recusa: ele sobe um nível territorial e devolve o primeiro nível seguro, com a explicação da política. Foi o que demonstramos: um recorte municipal abaixo de $k=5$ retornou a referência do polo regional, com 226 internações e taxa de 13,27% contra 11,97% do estado. **A contagem suprimida nunca aparece.**

P17. “Vocês afirmam zero data movement, mas usam um LLM externo. Não é contradição?” R. O núcleo é OML4Py: preparação, treino, avaliação e inferência acontecem no Autonomous Database, sem exportar a base. O Select AI não é apresentado como zero data movement absoluto: ele envia a pergunta e os metadados autorizados, e o SQL gerado é executado no Oracle. Nenhum dado de paciente sai. **SP.** A exposição foi reduzida estruturalmente: o perfil tem `enforce_object_list`

apontando só para views agregadas. Para o literal, a alternativa seria remover o LLM externo e manter apenas OML4Py, views e procedimentos.

Bloco D — A IA generativa

P18. “E se a Athena inventar um número?” R. Ela não tem como. Os números vêm de funções PL/SQL determinísticas; a Athena recebe um JSON pronto e narra. Nós proibimos explicitamente que ela faça qualquer cálculo novo, depois de ela ter calculado um “3,2 vezes” que a ferramenta não retornava. Esse foi um dos quatro pontos que reprovamos em QA antes de homologar.

P19. “E a descrição dos diagnósticos, ela inventa?” R. Não. Carregamos o dicionário CID-10 DATASUS V2008 dentro do Oracle, com 14.233 códigos e cobertura de 100% dos 1.599 usados pelo projeto. O modelo de linguagem não traduz código clínico por memória: ele narra o que o banco devolve, com código oficial, descrição e versão.

P20. “Vocês confiam no SQL que o LLM escreve?” R. Não. Usamos `SHOWSQL` para ver o SQL antes de executar. Três das cinco consultas foram recusadas na primeira tentativa: uma com valor de faixa etária errado, uma sem `NULLS LAST` (o que traria célula mascarada no topo) e uma sem desempate determinístico.

P21. “Por que sete ferramentas em vez de deixar o Agent consultar livremente?” R. Porque ferramenta determinística é auditável e reproduzível: mesma entrada, mesma saída, sempre. Vimos na prática o que acontece sem isso: numa rodada, o Agent filtrou um campo errado e reagregou uma view já agregada, produzindo um zero falso onde havia 11 células.

Bloco E — Produto e viabilidade

P22. “Quem é o cliente e quem paga?” R. Secretarias municipais e estaduais de saúde e departamentos regionais. O dado é público e nacional, então não há custo de aquisição de dado nem contrato de fornecimento. O custo é de infraestrutura e operação.

P23. “Isso funciona fora de São Paulo?” R. A arquitetura sim. As fontes são nacionais, o pipeline é o mesmo, e o que muda é o recorte territorial. São Paulo é o recorte de implantação, não o limite do desenho. O que precisaria ser refeito é o treino do modelo com o dado do novo estado e a revalidação.

P24. “Vocês conversaram com algum gestor de saúde real?” R. Não. A Marina é uma persona de demonstração construída a partir do problema que os dados revelam, e o material diz isso explicitamente. Validar com gestores é o próximo passo, e o produto já define o que medir num piloto: cobertura, tempo até contato, adesão e nova internação em 30 dias. *(Não tente contornar esta pergunta. A honestidade aqui protege toda a credibilidade construída nas outras respostas.)*

P25. “O ‘Acompanhar’ do EPAA funciona?” R. Parcialmente, e nós somos explícitos. O produto compara indicadores entre períodos mantendo as mesmas definições e o contexto territorial. O que ele **não** tem é dado de execução de intervenção, então “Acompanhar” hoje significa “o produto define o que medir quando a ação for executada”, não “resultados de telemonitoramento já foram observados”.

P26. “Por que leitos cadastrados e não leitos disponíveis?” R. Porque o CNES é cadastro, não operação. Disponibilidade de vaga em tempo real exigiria integração com o sistema de gestão hospitalar, e nós não afirmamos ter isso. Preferimos declarar o limite a sugerir uma capacidade que não medimos.

P27. “Qual o ganho concreto para o gestor?” R. Com a mesma equipe e a mesma capacidade de acompanhamento, ele passa a apontar essa capacidade para um grupo onde o desfecho é três vezes mais frequente que a média. O ganho é de **priorização**, não de efeito clínico demonstrado.

Bloco F — As perguntas difíceis

P28. “Quanto disso foi feito com IA?” R. Usamos assistência de IA em codificação e revisão, e isso está documentado no projeto. O que define a qualidade do trabalho não é a ferramenta, é o processo de verificação: três erros metodológicos foram encontrados e corrigidos justamente porque não aceitamos o primeiro resultado bonito. O 0,98 que descartamos é a prova disso.

P29. “Qual a maior fragilidade do trabalho?” R. *(Escolha uma e seja direto. Sugestão:)* A ausência de validação com usuário real. Construímos a partir do que o dado revela, não do que um gestor disse que precisa. É o primeiro item do próximo ciclo.

P30. “Se vocês tivessem mais um mês, o que fariam?” R. *(Três, em ordem:)* validar a persona com gestores reais; construir a versão prospectiva do modelo, com marco de previsão na admissão e só features disponíveis naquele instante; e desenhar um piloto de intervenção com grupo de comparação, para finalmente poder medir efeito em vez de só priorizar.

PARTE 10 — PENDÊNCIAS CONHECIDAS (USO INTERNO)

Não leve esta parte para o palco. Ela existe para vocês saberem onde estão pisando.

10.1 O critério “Uso Correto dos Formatos” — risco alto

O critério oficial da Oracle é **relacional + JSON + CSV, os três no mesmo banco**. A auditoria de 10/09, com query real rodada no Database Actions, encontrou:

1. **Relacional: OK.** As tabelas existem.
2. **JSON: FALHA.** Zero colunas de tipo JSON em qualquer schema do time.
3. **External Table: FALHA.** Só 5 external tables no banco inteiro, todas internas do Oracle/OCI, nenhuma do projeto.

Não há registro posterior de que isso tenha sido resolvido. As Tools devolvem CLOB JSON e o CID-10 entrou a partir de CSV, o que pode ou não satisfazer o avaliador.

É o item de maior retorno por minuto que resta. Criar uma External Table sobre um CSV que vocês já têm, e uma tabela com coluna de tipo JSON, são operações de poucos minutos no Oracle. Se der tempo antes da apresentação, faça. Se não der, saiba que o critério pode estar descoberto e **não invente** que está atendido.

10.2 Integração ponta a ponta

Não há registro de teste completo frontend → n8n/ORDS → Oracle → `CLARITI_GESTOR_TEAM` → frontend. Os itens do Codex em 14/09 que seguem em aberto:

- exibição dos campos CID-10 no frontend;
- confirmação de que o chat publicado aponta para o Team atualizado;
- qual view alimenta a capacidade de leitos exibida;
- identidade visual da Athena na aplicação.

10.3 Divergências numéricas entre gerações

Documentos antigos citam 783.860 elegíveis, 516.286 de treino e 267.574 de teste. A rodada oficial in-database traz 759.402 escorados e 248.507 no teste de 2024. **Use sempre a segunda.** Se alguém apontar, a resposta está na Parte 3.2.

Da mesma forma, AUC 0,6582/0,6927 e 0,6554/0,6943 são rodadas **locais** anteriores. A oficial é **0,731641**, medida no Oracle no teste fora do tempo completo.

10.4 O que ainda não foi isolado

- A causa exata da diferença numérica entre as rodadas A7 e A13 não foi identificada. Não atribua a uma versão de biblioteca sem ter verificado.
- O script original da rodada de sazonalidade não foi localizado; a fórmula foi reconstruída e reproduz os valores históricos, mas isso é reconstrução, não recuperação.
- O CSV mensal do SIA traz 646 municípios distintos, um a mais que os 645 oficiais. Não investigado, baixo risco.

FECHAMENTO

Três frases que resumem a defesa do trabalho inteiro:

1. **Nós medimos o risco antes de escolher a proteção.** A auditoria de reidentificação veio antes do $k=5$.
2. **Nós desconfiamos do nosso melhor resultado.** O 0,98 virou 0,73 porque fomos atrás, e isso é o oposto do que costuma acontecer.
3. **Nós separamos o que o número mostra do que ele não mostra.** Priorização não é redução, cadastro não é disponibilidade, e correlação não é causa.